

Eksplorasi Data Biomedis pada Penderita Diabetes

^{1st} Syahla Maharani Salsabila

SI Teknik Biomedis, Fakultas Teknik Elektro

Universitas Telkom

Bandung, Indonesia

syahlamaharani@student.telkomuniversity.ac.id

Abstract—Diabetes melitus adalah penyakit kronis yang dapat menyebabkan berbagai komplikasi serius jika tidak ditangani dengan baik. Analisis eksplorasi data (EDA) pada dataset diabetes dilakukan untuk memahami pola distribusi variabel, mendeteksi outlier, serta mengidentifikasi faktor-faktor utama yang berkaitan dengan kejadian diabetes. Metode Interquartile Range (IQR) diterapkan untuk mendeteksi dan menghapus outlier guna meningkatkan kualitas analisis. Hasil studi menunjukkan bahwa kadar glukosa memiliki korelasi tertinggi dengan kejadian diabetes, sementara variabel lain seperti ketebalan kulit dan tekanan darah juga berperan dalam menentukan risiko. Dengan analisis yang lebih dalam, hasil eksplorasi ini dapat digunakan sebagai dasar dalam pengembangan model prediksi diabetes yang lebih akurat.

Index Terms—Diabetes, Eksplorasi Data, Outlier, Korelasi, Interquartile Range (IQR).

I. PENDAHULUAN

Diabetes melitus merupakan salah satu penyakit kronis yang dapat menyebabkan komplikasi serius pada kesehatan. Penyakit diabetes terjadi karena adanya kelainan pada sekresi atau kerja insulin, yang menyebabkan tingginya kadar gula darah dalam tubuh. Kadar gula darah yang tinggi dapat merusak organ-organ seperti mata, ginjal, jantung, dan saraf [1]. Dengan prevalensi globalnya yang terus meningkat, penyakit diabetes menjadi salah satu masalah kesehatan paling penting dan menantang yang dihadapi manusia saat ini. Oleh karena itu, analisis data kesehatan sangat penting untuk mengidentifikasi faktor-faktor yang dapat meningkatkan risiko diabetes.

Eksplorasi data (EDA) memainkan peran penting dalam memahami karakteristik data biomedis, mengidentifikasi pola yang dapat digunakan dalam prediksi penyakit, serta menangani outlier yang dapat mempengaruhi hasil analisis. Laporan ini dibuat dengan tujuan untuk mengeksplorasi dataset diabetes secara statistik dan visual guna memahami distribusi variabel, mendeteksi outlier, serta mengidentifikasi faktor utama yang berkaitan dengan kejadian diabetes.

II. METODE

A. Dataset

Dataset yang digunakan dalam tugas ini yaitu dataset diabetes yang bersumber dari *National Institute of Diabetes and Digestive and Kidney Disease* (NIDDK) [2]. Dataset ini terdiri dari beberapa fitur numerik, seperti umur, tekanan darah, kadar glukosa, indeks massa tubuh (BMI), faktor genetik, jumlah kehamilan, dan ketebalan kulit yang terkait dengan

diabetes. Dataset ini juga memiliki variabel target *Outcome* yang menunjukkan apakah seseorang menderita diabetes (1) atau tidak (0). Secara khusus, semua pasien dalam dataset ini adalah perempuan setidaknya berusia 21 tahun dari keturunan Indian Pima.

B. Eksplorasi Data (EDA)

Eksplorasi awal dilakukan dengan melihat distribusi data pada setiap fitur serta melakukan analisis deskriptif dalam dataset diabetes. Untuk memvisualisasikan distribusi data tersebut, digunakan histogram dengan estimasi kepadatan kernel (KDE) untuk memahami pola sebaran nilai setiap variabel, apakah memiliki distribusi normal atau terdapat *skewness* (kemiringan). Kemudian, dilakukan analisis korelasi untuk mengidentifikasi hubungan antar variabel, terutama antara fitur-fitur independen dengan variabel target.

C. Identifikasi dan Penanganan Outlier

Outlier dalam dataset diidentifikasi menggunakan metode *Interquartile Range* (IQR), yang menghitung rentang antara kuartil pertama (Q1) dan kuartil ketiga (Q3). Sebuah nilai dianggap sebagai outlier jika berada di luar batas bawah ($Q1 - 1.5 * IQR$) atau batas atas ($Q3 + 1.5 * IQR$). Setelah mendeteksi outlier, akan dilakukan penanganan yaitu berupa penghapusan baris data yang mengandung nilai ekstrem.

III. DISKUSI

A. Statistik Deskriptif

Berikut adalah statistik deskriptif dari dataset diabetes yang digunakan.

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	Outcome
count	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000	768.000000
mean	3.845052	120.894531	69.105469	20.536458	79.799479	31.992578	0.471876	33.240885	0.348958
std	3.369578	31.972618	19.355807	15.952218	115.244002	7.884160	0.331329	11.760232	0.476951
min	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.078000	21.000000	0.000000
25%	1.000000	99.000000	62.000000	0.000000	0.000000	27.300000	0.243750	24.000000	0.000000
50%	3.000000	117.000000	72.000000	23.000000	30.500000	32.000000	0.372500	29.000000	0.000000
75%	6.000000	140.250000	80.000000	32.000000	127.250000	38.600000	0.626250	41.000000	1.000000
max	17.000000	199.000000	122.000000	99.000000	846.000000	67.100000	2.420000	81.000000	1.000000

Fig. 1. Tabel Statistik Deskriptif dari Dataset Diabetes.

Berdasarkan tabel tersebut, ditemukan bahwa pada beberapa fitur seperti kadar glukosa (*Glucose*), tekanan darah (*Blood-Pressure*), ketebalan kulit (*SkinThickness*), dan kadar insulin

memiliki nilai minimum 0, yang dalam konteks medis hal tersebut tidak memungkinkan. Hal ini mengindikasikan kemungkinan kesalahan pencatatan atau data yang hilang (*missing values*). Fitur kadar insulin memiliki nilai standar deviasi yang paling tinggi ($std = 115.24$), yang menunjukkan bahwa data ini memiliki variasi yang sangat besar dibandingkan fitur lainnya. Berdasarkan informasi pada fitur usia, dapat disimpulkan bahwa rentang usia pasien pada dataset ini yaitu dari 21 tahun hingga 81 tahun, dengan rata-rata usia yaitu sekitar 33 tahun.

B. Distribusi Data

Berikut merupakan visualisasi distribusi data dari fitur jumlah kehamilan, kadar glukosa, tekanan darah, dan ketebalan kulit.




Fig. 2. Visualisasi Distribusi Data dari Dataset Diabetes (1)

Pada fitur jumlah kehamilan, distribusi data menunjukkan bahwa sebagian besar individu dalam dataset memiliki jumlah kehamilan rendah (0–2), dengan jumlah kasus yang semakin berkurang seiring bertambahnya jumlah kehamilan. Pada fitur kadar glukosa, distribusi data cenderung mendekati distribusi normal, dengan puncak di sekitar nilai 100–125. Fitur tekanan darah menunjukkan pola distribusi normal dengan puncak di sekitar 70–80 mmHg, tetapi terdapat beberapa outlier di bagian bawah. Sedangkan pada fitur ketebalan kulit terdapat banyak nilai nol dan menunjukkan pola distribusi data yang cukup bervariasi.

Berikut merupakan visualisasi distribusi data dari fitur kadar insulin, indeks massa tubuh (BMI), faktor keturunan diabetes (*DiabetesPedigreeFunction*), dan umur.




Fig. 3. Visualisasi Distribusi Data dari Dataset Diabetes (2)

Data pada fitur kadar insulin menunjukkan distribusi yang sangat miring ke kanan, dengan banyak nilai nol dan sejumlah besar nilai ekstrem di bagian atas, yang menunjukkan adanya

banyak individu dengan kadar insulin yang tidak terdeteksi atau sangat rendah. Distribusi data pada fitur BMI berbentuk mendekati distribusi normal dengan puncak sekitar 30–35, tetapi terdapat outlier. Kemudian pada fitur faktor keturunan diabetes, distribusi data menunjukkan kemiringan ke kanan. Data pada fitur usia menunjukkan distribusi yang miring ke kanan, menunjukkan sebagian besar individu berada dalam rentang usia 20–50 tahun, dengan jumlah individu yang lebih sedikit di usia yang lebih tua.

Dataset ini terdiri dari 768 sampel, dengan variabel target *Outcome* yang bernilai 0 (tidak diabetes) atau 1 (diabetes). Gambar 4 menunjukkan bahwa 34.9% dari sampel menderita diabetes, sedangkan 65.1% lainnya tidak menderita diabetes.




Fig. 4. Persentase Penderita Diabetes

C. Deteksi dan Penanganan Outlier

Untuk mendeteksi outlier, digunakan visualisasi berupa boxplot. Berdasarkan visualisasi tersebut, dipilih beberapa fitur yang memiliki outlier terbanyak, yaitu tekanan darah, kadar insulin, faktor keturunan diabetes, dan BMI.




Fig. 5. Boxplot Distribusi Data pada Fitur dengan Outlier Terbanyak

Metode yang digunakan untuk menangani outlier dalam tugas ini adalah *Interquartile Range Method*. Pada metode ini, data yang berada di luar batas bawah (*lower bound*) dan batas atas (*upper bound*) dihapus dari dataset. Berikut adalah distribusi data pada fitur-fitur tersebut setelah dilakukan penghapusan outlier.

Sebelum penghapusan outlier, fitur tekanan darah menunjukkan beberapa titik data ekstrem yang berada di bawah 20 mmHg dan di atas 100 mmHg. Setelah proses penghapusan outlier dilakukan, distribusi data menjadi lebih normal dengan rentang yang lebih representatif, dan sebagian besar outlier telah berhasil dihilangkan.




Fig. 6. Boxplot Distribusi Data Setelah Penghapusan Outlier

Pada fitur Insulin, terdapat banyak nilai ekstrem yang melebihi 300, bahkan mencapai angka 800. Setelah penghapusan dilakukan, data menjadi lebih terkonsentrasi dalam rentang yang lebih wajar, meskipun masih terdapat beberapa outlier.

Fitur faktor keturunan diabetes menunjukkan keberadaan outlier yang cukup signifikan, terutama pada nilai yang lebih besar dari 2.0. Nilai-nilai ini mencerminkan riwayat keluarga yang memiliki kecenderungan tinggi terhadap diabetes. Setelah proses penghapusan dilakukan, rentang data menjadi lebih terbatas dan lebih mewakili distribusi utama, meskipun masih terdapat sedikit outlier yang tersisa.

Pada fitur BMI, terdapat beberapa individu dengan BMI yang sangat ekstrem, terutama di atas 50 dan beberapa di bawah 10. Nilai-nilai ini mungkin menunjukkan kesalahan input atau kondisi medis yang tidak umum. Setelah penghapusan, distribusi data pada fitur BMI menjadi lebih seimbang.

D. Korelasi antar Variabel

Untuk menggambarkan korelasi antar variabel pada dataset ini, digunakan matriks korelasi yang dinyatakan dalam rentang -1 hingga 1, dengan nilai positif menunjukkan hubungan searah, sedangkan nilai negatif menunjukkan hubungan berlawanan. Gambar 7 menunjukkan matriks korelasi antar variabel pada dataset diabetes.

Berdasarkan matriks tersebut, dapat diambil beberapa temuan utama, yaitu:

- Glukosa memiliki korelasi yang cukup kuat dengan *Outcome* (kemungkinan diabetes), dengan nilai yaitu 0.46, yang menunjukkan bahwa kadar glukosa yang lebih tinggi berkaitan dengan peningkatan risiko diabetes.
- Kadar insulin dengan kemungkinan diabetes memiliki korelasi yang rendah, yaitu dengan nilai 0.10, yang menunjukkan bahwa semakin rendah kadar insulin dalam tubuh, maka individu tersebut semakin berisiko terkena penyakit diabetes.
- Kadar insulin dan ketebalan kulit memiliki korelasi yang cukup tinggi, dengan nilai 0.47. Hal ini karena ketebalan kulit sering digunakan sebagai indikator lemak tubuh yang berhubungan dengan resistensi insulin.
- Terdapat korelasi sedang antara umur dan tekanan darah, dengan nilai yaitu 0.34, yang dapat menunjukkan bahwa semakin bertambah usia seseorang, cenderung terjadi peningkatan tekanan darah.




Fig. 7. Matriks Korelasi untuk Dataset Diabetes

Sebagian besar variabel lainnya memiliki korelasi yang rendah satu sama lain, yang menunjukkan bahwa tidak ada hubungan yang sangat kuat antara sebagian besar fitur dalam dataset ini.

IV. KESIMPULAN

Hasil eksplorasi data menunjukkan bahwa kadar glukosa memiliki hubungan paling kuat dengan diabetes, sehingga dapat menjadi indikator utama dalam menentukan risiko penyakit ini. Metode IQR digunakan untuk menemukan dan menghapus nilai-nilai ekstrem (outlier), sehingga data menjadi lebih rapi dan mudah dianalisis. Selain glukosa, faktor lain seperti ketebalan kulit dan tekanan darah juga berpengaruh terhadap diabetes, meskipun dalam tingkat yang lebih rendah. Dengan pemahaman yang lebih baik terhadap data ini, diharapkan pada studi selanjutnya dapat dikembangkan model prediksi yang lebih akurat untuk membantu deteksi dini penyakit diabetes.

REFERENCES

- [1] M. Z. Bandy, A. S. Sameer, and S. Nissar, "Pathophysiology of diabetes: An overview," *Avicenna J Med*, vol. 10, no. 04, pp. 174–188, Oct. 2020.
- [2] A. D. Khare, "Diabetes Dataset," Kaggle, 2023. [Online]. Tersedia di: <https://www.kaggle.com/datasets/akshaydattatraykhare/diabetes-dataset>. [Diakses pada 29 Maret 2025].