

Prediksi Risiko Penyakit Diabetes Menggunakan Random Forest Classifier

Syahla Maharani Salsabila
S1 Teknik Biomedis, Fakultas Teknik Elektro
Universitas Telkom
Bandung, Indonesia
syahlamaharani@student.telkomuniversity.ac.id

Abstrak— Diabetes melitus merupakan penyakit kronis yang prevalensinya terus meningkat secara global dan dapat menimbulkan komplikasi serius pada organ tubuh. Dalam upaya mencegah risiko, prediksi dini melalui analisis data kesehatan menjadi sangat penting. Laporan ini bertujuan untuk menerapkan algoritma *Random Forest Classifier* dalam memprediksi risiko diabetes berdasarkan dataset dari National Institute of Diabetes and Digestive and Kidney Disease (NIDDK). Proses eksplorasi data dilakukan untuk memahami hubungan antar variabel, diikuti oleh penanganan outlier dengan metode *Interquartile Range* (IQR), serta transformasi fitur BMI dan glukosa menjadi kategori yang lebih representatif. Model *Random Forest* menghasilkan akurasi sebesar 82% dengan nilai AUC sebesar 0.86, menunjukkan performa klasifikasi yang sangat baik dalam membedakan antara penderita dan non-penderita diabetes. Hasil ini memperlihatkan potensi *machine learning* dalam membantu deteksi dini risiko diabetes.

Kata Kunci—Diabetes, Eksplorasi Data, Machine Learning, Random Forest Classifier

I. PENDAHULUAN

Diabetes melitus merupakan salah satu penyakit kronis yang dapat menyebabkan komplikasi serius pada kesehatan. Penyakit diabetes terjadi karena adanya kelainan pada sekresi atau kerja insulin, yang menyebabkan tingginya kadar gula darah dalam tubuh. Kadar gula darah yang tinggi dapat merusak organ-organ seperti mata, ginjal, jantung, dan saraf [1]. Menurut *World Health Organization* (WHO) dan *International Diabetes Federation* (IDF), pada tahun 2021 terdapat sekitar 537 juta orang dewasa di dunia yang mengidap diabetes, dengan angka kematian mencapai 6,7 juta jiwa setiap tahunnya [2]. Dengan prevalensi globalnya yang terus meningkat, penyakit diabetes menjadi salah satu masalah kesehatan paling penting dan menantang yang dihadapi manusia saat ini. Oleh karena itu, analisis data kesehatan sangat penting untuk mengidentifikasi faktor-faktor yang dapat meningkatkan risiko diabetes.

Eksplorasi data (EDA) memainkan peran penting dalam memahami karakteristik data biomedis, mengidentifikasi pola yang dapat digunakan dalam prediksi penyakit, serta menangani outlier yang dapat mempengaruhi hasil analisis. Melalui EDA, akan diperoleh wawasan awal mengenai distribusi variabel, hubungan antar fitur, serta potensi masalah seperti data yang hilang. Hal ini dapat menjadi fondasi untuk langkah selanjutnya yaitu membuat model prediktif.

Seiring berkembangnya teknologi, pemanfaatan *machine learning* dalam bidang kesehatan, khususnya untuk prediksi dan klasifikasi penyakit, semakin banyak dilakukan. Salah satu algoritma yang efektif digunakan untuk mengklasifikasi data medis adalah *Random Forest Classifier* [3]. Algoritma ini dikenal mampu menangani data dengan fitur yang kompleks serta memberikan hasil evaluasi yang stabil, sehingga sesuai

untuk diaplikasikan pada data medis, termasuk prediksi risiko diabetes [4].

Laporan ini dibuat dengan tujuan untuk menerapkan dan mengevaluasi algoritma *Random Forest Classifier* dalam memprediksi risiko diabetes, serta menganalisis performa model dalam mengidentifikasi faktor-faktor utama yang berpengaruh terhadap penyakit diabetes.

II. METODE

A. Dataset dan Eksplorasi Data

Dataset yang digunakan dalam tugas ini yaitu dataset diabetes yang bersumber dari National Institute of Diabetes and Digestive and Kidney Disease (NIDDK) [5]. Dataset ini terdiri dari beberapa variabel sebagai berikut (Tabel 1).

Tabel 1. Variabel dalam Dataset Diabetes.

Kategori	Jumlah	Variabel
Numerik	8	Age, BloodPressure, Glucose, BMI, Insulin, DiabetesPedigreeFunction, Pregnancies, SkinThickness.
Target	1	Outcome (Non-Diabetes, Diabetes)

Dataset terdiri dari 768 sampel yang seluruhnya merupakan perempuan minimal berusia 21 tahun dari keturunan Indian Pima. Eksplorasi data dilakukan dengan melakukan analisis korelasi untuk mengidentifikasi hubungan antar fitur-fitur independen dengan variabel target.

B. Penanganan Outlier

Outlier dalam dataset diidentifikasi menggunakan metode *Interquartile Range* (IQR). Sebuah nilai dianggap sebagai outlier jika berada di luar batas atau batas atas. Berikut ini merupakan persamaan yang digunakan untuk menentukan batas atas (Persamaan 1) dan batas bawah (Persamaan 2).

$$\text{Batas Bawah} = Q_1 - 1.5 \times IQR \quad (1)$$

$$\text{Batas Atas} = Q_3 + 1.5 \times IQR \quad (2)$$

Setelah mendeteksi outlier, akan dilakukan penanganan yaitu dengan cara mengganti nilai-nilai outlier tersebut dengan nilai median pada masing-masing fitur, agar distribusi data tetap representatif tanpa menghilangkan observasi yang mungkin penting.

C. Pra-Pemrosesan Data

Pra-pemrosesan data dilakukan untuk memastikan bahwa data yang digunakan dalam pelatihan model *machine learning* bersih, seimbang, dan sesuai untuk proses klasifikasi. Berikut merupakan tahapan pra-pemrosesan data yang digunakan.

1) Feature Engineering

Feature engineering bertujuan untuk meningkatkan kualitas data dengan melakukan transformasi terhadap fitur-fitur dari dataset asli. Adapun dua fitur variabel atau fitur utama yang akan dilakukan transformasi ke dalam bentuk kategorikal, yaitu BMI dan kadar glukosa. Hasil transformasi tersebut kemudian diubah menjadi format numerik menggunakan teknik *one-hot encoding*, sehingga dapat dikenali dan dipelajari secara efektif oleh model.

2) Pembagian Data

Pada tahap ini, dataset akan dibagi menjadi dua bagian, yaitu data latih dan data uji, dengan proporsi masing-masing 80% dan 20%. Pembagian dilakukan dengan fungsi `train_test_split` dari *library* `scikit_learn` secara acak.

D. Model Machine Learning

Model yang digunakan adalah *Random Forest Classifier*, yaitu metode *ensemble learning* yang menggabungkan banyak pohon keputusan. Model ini bekerja dengan cara membangun beberapa pohon keputusan secara paralel dan menentukan prediksi berdasarkan suara terbanyak [6]. Berikut merupakan parameter *Random Forest Classifier* yang diimplementasikan dalam model ini:

- `class_weight`: 'balanced'
- `max_depth`: None
- `max_features`: 0.75
- `min_samples_leaf`: 1
- `min_samples_split`: 2
- `n_estimators`: 250

III. DISKUSI DAN HASIL

A. Karakteristik Dataset dan Eksplorasi Data

Dataset ini terdiri dari 768 sampel, dengan variabel target Outcome yang bernilai 0 (tidak diabetes) atau 1 (diabetes). Gambar 1 menunjukkan bahwa 65.1% dari sampel tidak menderita diabetes, sedangkan 34.9% lainnya menderita diabetes. Berikut merupakan distribusi jumlah sampel pada dataset berdasarkan variabel target Outcome (Gambar 1).




Fig. 1. Jumlah Sampel berdasarkan Outcome.

Untuk menggambarkan korelasi antar variabel pada dataset ini, digunakan *heatmap correlation* yang dinyatakan dalam rentang -1 hingga 1, dengan nilai positif menunjukkan hubungan searah, sedangkan nilai negatif menunjukkan hubungan berlawanan. Gambar 2 menunjukkan peta korelasi antar variabel pada dataset diabetes.



Fig. 2. Heatmap Correlation untuk Dataset Diabetes.

Berdasarkan peta korelasi tersebut, dapat diambil beberapa temuan utama, yaitu:

- Glucose memiliki korelasi yang cukup kuat dengan Outcome (kemungkinan diabetes), dengan nilai yaitu 0.47, yang menunjukkan bahwa kadar glukosa yang lebih tinggi berkaitan dengan peningkatan risiko diabetes.
- BMI atau indeks massa tubuh memiliki korelasi yang cukup signifikan dengan Outcome (0.29), yang menunjukkan bahwa obesitas atau berat badan berlebih memiliki hubungan dengan peningkatan risiko diabetes.
- Age juga memiliki korelasi dengan Outcome (0.24), yang dapat menunjukkan risiko diabetes akan meningkat seiring bertambahnya usia.
- Pregnancies memiliki korelasi positif lemah dengan Outcome (0.22), yang dapat menunjukkan bahwa kehamilan yang sering akan meningkatkan risiko diabetes.

B. Penanganan Outlier

Outlier dalam dataset diidentifikasi menggunakan metode Interquartile Range (IQR), yang menghitung rentang antara kuartil pertama (Q1) dan kuartil ketiga (Q3). Berikut merupakan hasil deteksi outlier menggunakan metode IQR pada dataset (Tabel 2). Berdasarkan hasil deteksi, beberapa fitur yang memiliki outlier terbanyak, yaitu tekanan darah (BloodPressure), kadar insulin (Insulin), faktor keturunan diabetes (DiabetesPedigreeFunction), dan BMI.

Tabel. 2. Hasil Deteksi Outlier menggunakan IQR.

Variabel	Jumlah Outlier
Pregnancies	4
Glucose	5
BloodPressure	45

SkinThickness	1
Insulin	34
BMI	19
DiabetesPedigreeFunction	29
Age	9

Untuk mengatasi outlier tersebut, digunakan pendekatan berupa mengganti nilai outlier dengan median dari masing-masing variabel. Pendekatan ini dipilih agar distribusi data menjadi lebih stabil tanpa mengorbankan ukuran dataset. Setelah proses penggantian dilakukan, dilakukan pengecekan ulang untuk memastikan jumlah outlier yang masih tersisa. Hasil akhir menunjukkan bahwa sebagian besar nilai ekstrem berhasil dinormalisasi, sehingga dataset menjadi lebih bersih dan siap digunakan dalam proses pelatihan model *machine learning*.

C. Feature Engineering

Feature Engineering merupakan tahapan yang bertujuan untuk menciptakan variabel atau fitur baru dari data mentah yang sudah ada. Berikut merupakan rincian dari fitur yang akan ditransformasi.

1) BMI

Pada tahap pertama, dilakukan transformasi nilai BMI numerik menjadi enam kategori yang mengikuti klasifikasi standar internasional (Tabel 3). Pembagian kategori dilakukan berdasarkan nilai ambang batas yang telah ditetapkan oleh National Institute of Health (NIH) dan World Health Organization (WHO) [7].

Tabel. 3. *Feature Engineering* untuk Fitur BMI.

Kategori	Ambang Batas
Underweight	BMI < 18.5
Normal	18.5 < BMI ≤ 24.9
Overweight	24.9 < BMI ≤ 29.9
Obesity 1	29.9 < BMI ≤ 34.9
Obesity 2	34.9 < BMI ≤ 39.9
Obesity 3	BMI > 39.9

2) Kadar Glukosa

Kategorisasi glukosa darah dilakukan dengan membagi nilai numerik menjadi empat kategori yang mencerminkan tingkat risiko diabetes (Tabel 4). Pembagian kategori dilakukan berdasarkan standar yang diterapkan oleh American Diabetes Association (ADA) [8].

Tabel. 4. *Feature Engineering* untuk Fitur Kadar Glukosa.

Kategori	Ambang Batas
Low	Glucose < 70 mg/dL
Normal	70 < Glucose ≤ 99 mg/dL
Prediabetic	99 < Glucose ≤ 126 mg/dL
Diabetic	Glucose > 126 mg/dL

Setelah menambahkan variabel baru, tahap selanjutnya dari *feature engineering* ini yaitu transformasi semua variabel kategorikal yang telah dibuat menjadi format yang dapat diproses oleh algoritma *machine learning* melalui teknik *one-hot encoding*.

D. Kinerja Model Random Forest Classifier

Dataset akan dibagi menjadi dua bagian, dengan persentase yaitu 80% untuk data latih dan 20% untuk data uji. Model dievaluasi dengan menggunakan *classification report* (Tabel 5), *confusion matrix* (Gambar 3). Selain itu, model juga dievaluasi menggunakan kurva *Receiver Operating Characteristic* (ROC).

Tabel. 3. *Classification Report* dari Model Random Forest Classifier

	Precision	Recall	F-1 Score	Support
0	0.87	0.87	0.87	107
1	0.70	0.70	0.70	47
Accuracy			0.82	154
Macro avg	0.79	0.79	0.79	154
Weighted avg	0.82	0.82	0.82	154

Model *Random Forest* berhasil mencapai akurasi sebesar 82%, yang berarti dari total 154 data uji, sebanyak 82% di antaranya berhasil diklasifikasikan dengan benar. Nilai *precision*, *recall*, dan *f1-score* untuk kelas 0 (tidak diabetes) cukup tinggi yaitu 0.87, menunjukkan bahwa model sangat baik dalam mengenali individu yang tidak menderita diabetes. Namun, untuk kelas 1 (penderita diabetes), *precision*, *recall*, dan *f1-score* berada pada angka 0.70, yang menunjukkan bahwa model cukup baik dalam mendeteksi penderita diabetes, meskipun masih ada kesalahan klasifikasi yang terjadi. Hal ini dapat dikatakan masih dalam batas wajar, mengingat distribusi data tidak seimbang karena jumlah penderita diabetes lebih sedikit dibandingkan non-diabetes (47 vs 107).




Fig. 3. *Confusion Matrix* dari Model Random Forest Classifier

Berdasarkan hasil dari *confusion matrix*, diperoleh bahwa dari total 154 data uji, sebanyak 93 sampel kelas 0 (tidak menderita diabetes) berhasil diklasifikasikan dengan benar (*true negative*), sementara 33 sampel kelas 1 (menderita diabetes) juga berhasil dikenali dengan tepat (*true positive*). Namun, terdapat 14 kasus *false positive*, yaitu individu yang sebenarnya tidak menderita diabetes namun diprediksi positif oleh model, serta 14 kasus *false negative*, yaitu individu yang sebenarnya menderita diabetes tetapi tidak terdeteksi oleh

model. Secara umum, *confusion matrix* ini menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan dua kelas.

Berikut merupakan kurva ROC dari model *Random Forest Classifier* (Gambar 4).




Fig. 4. Kurva ROC dari Model *Random Forest Classifier*

Kurva ROC menunjukkan performa model *Random Forest Classifier* dalam membedakan antara kelas positif (penderita diabetes) dan kelas negatif (tidak menderita diabetes). Berdasarkan hasil tersebut, diperoleh nilai AUC (*Area Under Curve*) sebesar 0.86, yang mengindikasikan bahwa model memiliki kemampuan klasifikasi yang sangat baik. Semakin tinggi nilai AUC, semakin tinggi juga probabilitas model dalam memisahkan kedua kelas dengan benar. Nilai 0.86 menunjukkan bahwa model secara konsisten mampu membedakan pasien yang menderita diabetes dengan yang tidak, jauh lebih baik daripada tebakan acak ($AUC = 0.5$). Hasil Kurva ROC ini memperkuat bahwa *Random Forest Classifier* merupakan model yang efektif dan andal untuk digunakan dalam prediksi penyakit diabetes pada dataset ini.

E. Feature Importance

Berikut merupakan grafik *Feature Importance* dari model *Random Forest Classifier* yang digunakan (Gambar 5).




Fig. 5. Grafik *Feature Importance* dari Model *Random Forest Classifier*

Berdasarkan grafik *feature importance*, dapat dilihat bahwa fitur Glucose memiliki kontribusi paling besar dalam proses klasifikasi risiko diabetes. Hal ini menunjukkan bahwa kadar glukosa dalam darah merupakan indikator

utama dalam menentukan apakah seseorang menderita diabetes. Selanjutnya, fitur BMI dan Age juga memiliki peran signifikan. Nilai *importance* yang tinggi pada BMI menegaskan bahwa obesitas merupakan salah satu faktor risiko utama diabetes, sementara faktor usia menunjukkan bahwa risiko diabetes cenderung meningkat seiring bertambahnya umur. Fitur-fitur lain seperti BloodPressure, Pregnancies, SkinThickness, dan Insulin memberikan kontribusi sedang, yang menandakan bahwa meskipun tidak dominan, fitur-fitur tersebut tetap relevan dalam membantu model mengenali pola risiko diabetes.

IV. KESIMPULAN

Model *Random Forest Classifier* berhasil menunjukkan performa yang baik dalam memprediksi risiko diabetes dengan akurasi sebesar 82% dan nilai AUC sebesar 0.86. Proses pra-pemrosesan data seperti penanganan outlier dan transformasi fitur BMI serta glukosa menjadi kategori memberikan kontribusi signifikan terhadap peningkatan akurasi model. Hasil evaluasi menunjukkan bahwa variabel glukosa, BMI, dan usia merupakan fitur yang memiliki korelasi cukup kuat terhadap kemungkinan seseorang menderita diabetes. Dengan demikian, pendekatan ini dapat menjadi alat bantu yang efektif untuk mendeteksi risiko diabetes secara dini dan mendukung pengambilan keputusan dalam bidang kesehatan.

REFERENSI

- [1] M. Z. Banday, A. S. Sameer, and S. Nissar, "Pathophysiology of diabetes: An overview," *Avicenna J Med*, vol. 10, no. 04, pp. 174–188, Oct. 2020, doi: 10.4103/ajm.ajm_53_20.
- [2] Hartono and S. Ediyono, "50 RELATIONSHIP BETWEEN LEVEL OF EDUCATION, DURATION OF ILLNESS, AND LEVEL OF KNOWLEDGE OF THE 5 PILLARS OF DIABETES MELLITUS MANAGEMENT IN THE WORKING AREA OF SUNGAI DURIAN COMMUNITY HEALTH CENTRE, KUBU RAYA DISTRICT, WEST KALIMANTAN," *Journal of The Shine Cahaya Dunia S-1 Keperawatan*, vol. 9, no. 1, pp. 2775–3045, 2024, [Online]. Available: <http://ejournal.annurpurwodadi.ac.id/index.php/TSCS1Kep>
- [3] R. Maulana, M. F. Hasan, F. Raehan, and M. Ramzy, "Literature Review : Penerapan Algoritma Random Forest untuk Klasifikasi Penyakit Diabetes," *Buletin Ilmiah Ilmu Komputer dan Multimedia*, vol. 2, no. 3, pp. 550–555, Oct. 2024, [Online]. Available: <https://jurnalmahasiswa.com/index.php/biikma>
- [4] S. Firdous, G. A. Wagai, and K. Sharma, "A survey on diabetes risk prediction using machine learning approaches," *J Family Med Prim Care*, vol. 11, no. 11, pp. 6929–6934, Nov. 2022, doi: 10.4103/jfmpc.jfmpc_502_22.
- [5] A. D. Khare, "Diabetes Dataset," Kaggle, 2023. Accessed: May 22, 2025. [Online]. Available: <https://www.kaggle.com/datasets/akshaydattatraykhare/diabetes-dataset>
- [6] Sriyanto and A. Ria Supriyatna, "Prediksi Penyakit Diabetes Menggunakan Algoritma Random Forest," *Jurnal Teknik*, vol. 17, pp. 163–172, 2023.
- [7] C. B. Weir and A. Jan, "BMI Classification Percentile and Cut Off Points," in *Treasure Island (FL)*, StatPearls Publishing, 2023. Accessed: Jun. 01, 2025. [Online]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK541070/>
- [8] N. A. ElSayed *et al.*, "Classification and diagnosis of diabetes: Standards of care in diabetes-2023," *Diabetes Care*, vol. 46, no. Suppl 1, pp. S19–S40, Jan. 2023.